

Introdução ao Pré-processamento

Camaçari

Feira de Santana, 2026

Agenda

Nosso objetivo é desenvolver o nosso modelo de recomendação para os usuários.

1. Introdução e Contexto:

Importancia e Exemplo

2. Pré-processamento e Exemplos:

Dados Duplicados ou Ausentes,
Normalização e Tradutor

3. Resultado Prático:

Antes e Depois

Introdução e Contexto



- Imagine um chef de cozinha. Se ele tiver ingredientes sujos e podres, fará uma comida horrível. O Pré-processamento é o assistente que limpa e separa os ingredientes antes de entregar para o chef.
- Nós pegamos o banco de dados de músicas do Spotify e o "limpamos" para que o nosso sistema consiga fazer boas recomendações.

Pré-processamento

Dados Duplicados



drop_duplicates

- Como gerenciar respostas repetidas (bug do sistema, erro do usuario...)?
- Criamos um filtro que escaneia a lista inteira e deleta os "**clones**", garantindo que cada informação seja única e verdadeira.

Pré-processamento

Dados Duplicados

	Pet	Color	Eyes
0	Cat	Brown	Black
1	Dog	Golden	Black
2	Dog	Golden	Black
3	Dog	Golden	Brown
4	Cat	Black	Green



	Pet	Color	Eyes
0	Cat	Brown	Black
1	Dog	Golden	Black
3	Dog	Golden	Brown
4	Cat	Black	Green

Pré-processamento

Dados Ausentes



MissingValueProcessor

- Como gerenciar respostas que são deixadas em branco?
- Se falta informação de um campo como a “popularidade”, a gente não apaga a música inteira. Nós preenchemos esse buraco com a **média** das outras músicas.

Pré-processamento

Dados Ausentes

**Antes: Dados com
Valores Ausentes**

Idade	Salário
25	3000
30	NaN
NaN	4500
40	5000
NaN	4000

*NaN = Valor Ausente



**Depois: Dados Após
Imputação (Média)**

Idade	Salário
25.00	3000.0
30.00	4125.0
31.67	4500.0
40.00	5000.0
31.67	4000.0

- Média da Idade: 31.67
- Média do Salário: 4125.0

Pré-processamento

Normalização



Scaler

- Como gerenciar medidas distintas?
- "**Esmagamos**" todos os números para ficarem entre 0 e 1. Assim, independente dos valores, fica tudo justo e na mesma escala.

Pré-processamento

Normalização

Dados Originais			Min-Max Scaler		
Duração	Popularidade	Volume (dB)	Duração	Popularidade	Tempo (BPM)
180	75	120	0.18	0.63	0.50
210	60	130	0.48	0.38	0.80
260	45	90	0.20	0.90	0.00
145	90	140	0.00	0.00	0.00
230	50	100	0.68	0.25	0.30

Pré-processamento

Tradutor




Encoder

- Como resolver a categorização nominal?
- Implementamos o **One-Hot Encoding**. Em vez de dar uma nota falsa para o gênero musical, nós criamos várias colunas novas.

Pré-processamento


Tradutor



Resultado Prático

- “Como era a tabela antes do pré-processamento”

INCOMPLETO



Resultado Prático

- “Como ficou a tabela após o pré-processamento”

INCOMPLETO

